

GÉNÉRALITÉS SUR LE DATA MINING

1. MOTIVATIONS ET DEFINITION DU DATA MINING

1.1. Exemple introductif

- *Un client vient demander un crédit à une banque*
- *Le banquier cherche à savoir s'il va rembourser le crédit ou non*
- *Le client ne dira jamais qu'il ne va pas rembourser, mais le banquier peut inférer sur le comportement futur du client à partir de la base de données des anciens clients*

1.2. Explosion des données

1) Développement et popularisation des de outils de production de données

- Développement de la technologie des bases de données, des entrepôts de données, outils d'acquisition automatique de données
- Popularisation des systèmes informatiques, et élévation de la conscience des utilisateurs des technologies de l'information
- Baisse des prix des équipements informatiques
- UC Berkeley en 2003 a estimé: 5 exabytes (5 millions terabytes) nouvelles données générées en 2002

www.sims.berkeley.edu/research/projects/how-much-info-2003




Figure N°1: Sondage sur le volume de données analysées (<http://www.kdnuggets.com>, 2013)

2) Sources variées et hétérogènes des données

- Les données sont générées par: les banques, les compagnies d'assurance, les réseaux de supermarchés, les hôpitaux, les compagnies de téléphonie, etc.
- Données expérimentales: physique, astronomie, biologie, etc.
- Web, texte, e-commerce
- Le plus grand «producteur de données» : USA (~40% des données mondiales)

3) Quelques grands producteurs de données

- Very Long Baseline Interferometry (VLBI) possède 6 télescopes, dont chacun produit **1 Gigabit/second** de données astronomiques pendant une session de 25 jours d'observations

- AT&T manipule des milliards de liaisons par jour
- Le réseau de distribution Wal-Mart emmagasine par jour des données relatives à plus de **20 millions** de transactions
- La compagnie Mobil Oil développe un entrepôt de données permettant d'emmagasiner plus de **100 tera bytes de données relatives à l'exploitation du pétrole**
- Le système satellitaire d'observation EOS génère chaque heure des **dizaines de gigabytes** de données
- Un supermarché de taille moyenne enregistre chaque jour la vente de **milliers d'articles**

4) Les plus grands systèmes de bases de données

- Bases de données commerciales :
 - France Telecom : ~30TB;
 - AT&T : ~ 26 TB
- Web
 - Google - 8 milliards de pages web
 - Yahoo - 20 milliards de pages web
 - IBM Web Fountain, 160 TB (2003)
 - Internet archive (www.archive.org), ~ 300 TB

1.3. Motivations du Data Mining

- Nous sommes inondés de données, et il nous manque les connaissances contenues dans ces données

- Seulement une infime partie des données produites est analysée, puis utilisée dans la pratique
- Il devient nécessaire d'analyser les données enregistrées, sinon leur stockage n'a pas de sens
- Il faut développer des outils et des méthodes pour rendre possible l'analyse des données de très grande taille
- Désir d'amélioration de la productivité
 - Forte pression due à la concurrence du marché
 - Brièveté du cycle de vie des produits
 - Besoin de prendre des décisions stratégiques efficaces
 - Exploiter le vécu (données historiques) pour prédire le futur et anticiper le marché
 - individualisation des consommateurs

1.4. Qu'est-ce que le Data Mining ?

1.4.1. Types de requêtes aux magasins de données

On peut distinguer 3 types de requêtes aux magasins de données (en particulier les bases de données) : requêtes opérationnelles, requêtes analytiques (basées sur le modèle OLAP), requêtes exploratoires

Exploration de données => requêtes complexes

- **Requête de type opératoire sur une base de données:**

Combien de bouteilles de vin a-t-on vendu au 1^{er} trimestre de 2010 dans la boutique EREVAN à Cotonou ?

■ **Requête de type analytique à un entrepôt de données :**

Combien de bouteilles de vin a-t-on vendu au 1^{er} trimestre, de 2010 dans le réseau de distribution EREVAN sur le territoire national par département, par marque et par trimestre pendant les 5 dernières années ?

Remarque : Une analyse comparative des données agrégées, ce qui est la base pour le modèle OLAP, opère à un niveau très détaillé de l'abstraction et ne permet pas l'élaboration de requêtes plus générales.

■ **Requêtes exploratoires :**

Les requêtes de type exploratoire ont un caractère beaucoup plus général et beaucoup plus abstrait :

- *Quels autres produits sont le plus souvent achetés par les clients qui achètent le vin ?*
- *Quelle est la différence entre les paniers du client qui achète le vin et du client qui achète la bière ?*
- *Comment peut-on caractériser les acheteurs de vin ?*
- *Peut-on prédire qu'un client va acheter du vin ?*
- *Quels sont les produits que les clients du supermarché achètent souvent avec du vin ?*
- *Quelles branches de supermarché ont connu de vente « anormale » dans le premier trimestre de 2004 ?*
- *Peut-on prédire le comportement futur des clients ?*
- *Y a-t-il une corrélation entre l'emplacement de la branche du super marché et la gamme de produits dont la vente est supérieure à la moyenne vendue des produits ?*
- *Étant donné le fichier de données sur les patients d'un hôpital :*
 - 1) *Faire le diagnostic correct du patient (déterminer le mal dont il souffre)*
 - 2) *Prédire correctement le résultat de la thérapie*

3) Proposer la meilleure thérapie

Remarque : Les requêtes du genre exploratoire ne peuvent pas être réalisées avec l'aide de SQL ou même ses extensions sous forme de requêtes analytiques.

1.4.2. Définition du Data Mining

Le Data Mining : Ensemble de méthodes et de techniques d'analyse de données et d'extraction d'informations structurées en vue d'aider à la prise de décision.




Figure N°2 : Une vue simplifiée du Data Mining

Les modèles sont le «produit» du Data Mining.

Les décisions stratégiques sont basées sur les modèles inférées par le Data Mining

Le concept de Data Mining apparaît en 1989 sous un premier nom de KDD (Knowledge Discovery in Databases, en français ECD pour Extraction de Connaissances à partir des Données), avant qu'en 1991 apparaisse pour la première fois le terme de DataMining ou « minage / fouille des données».

Aujourd'hui, le Data Mining se présente donc comme un outil incontournable au sein des processus décisionnels d'une entreprise.

1.4.3. Qu'est-ce que le Data Mining n'est pas ?

- Data warehouse
- SQL

- Système à base d'agents
- OnLine Analytical Processing (OLAP)
- Visualisation de données
- Statistiques descriptives
- Boule de cristal : Il ne devine pas le profil des clients à cibler, ceux sur le départ, etc. Il extrapole à partir des données disponibles

2. FONCTIONS ET ALGORITHMES DU DATA MINING

2.1. Le Data Mining comme une convergence de plusieurs disciplines

Le Data Mining met en œuvre un **ensemble de techniques** issues des statistiques, de l'analyse de données et de l'informatique pour explorer les données.




Figure N°3 : Différentes techniques qui participent au Data mining

2.2. Typologie des méthodes et des tâches du Data Mining

2.2.1. Selon les objectifs

- **Classification:** consiste à examiner les caractéristiques d'un objet et lui attribuer une classe

Exemples :

- *Attribuer ou non un prêt à un client*
- *Établir un diagnostic*

Méthodes utilisées :

- Arbres de décision
- K plus proches voisins
- Réseaux de neurones

- **Prédiction:** consiste à prédire la valeur future d'un attribut en fonction d'autres attributs

Exemple :

Prédire la "qualité" d'un client en fonction de son revenu, de son nombre d'enfants,...

Méthodes utilisées :

- Arbres de décision
- Réseaux de neurones

- **Association:** consiste à déterminer les attributs qui sont corrélés

Exemple :

Analyse du panier : ex. poisson et vin blanc

Méthodes utilisées :

- Règles d'association : Apriori, PFGroth

- **Segmentation:** consiste à former des groupes homogènes à l'intérieur d'une population

Exemple :

Tâche souvent faite avant les précédentes pour trouver les groupes sur lesquels appliquer la classification.

Méthodes utilisées :

- k moyennes (ou K-means)
- K plus proches voisins (K-nearest-neighbor)
- Réseaux de neurones




Figure N°4 : Sondage sur les algorithmes pour le Data mining (<http://www.kdnuggets.com>, 2011)

2.2.2. Selon le type d'apprentissage: Apprentissage supervisé / non supervisé

- ***Apprentissage supervisé***: processus dans lequel l'apprenant reçoit des exemples d'apprentissage comprenant à la fois des données d'entrée et de sortie

Objectif :

- Classification

- Prédiction

- **Apprentissage non supervisé:** processus dans lequel l'apprenant reçoit des exemples d'apprentissage ne comprenant que des données d'entrée

Objectif :

- Association
- Segmentation

2.2.3. Selon les types de modèles obtenus : modèles prédictifs, modèles descriptifs

- **Modèles prédictifs:** utilisent les données avec des résultats connus pour développer des modèles permettant de prédire les valeurs d'autres données

Le Data Mining prédictif: Extrapoler des nouvelles informations à partir de données existantes.

Exemple: modèle permettant de prédire les clients qui ne rembourseront pas leur crédit

Objectif:

- Classification
- Prédiction

- **Modèles descriptifs:** proposent des descriptions des données pour aider à la prise de décision. Les modèles descriptifs aident à la construction de modèles prédictifs

Le Data Mining descriptif: Mettre en évidence des informations présentes mais noyées par le volume de données.

Exemple : Anticiper les besoins de la clientèle et adapter la stratégie de l'entreprise aux attentes du marché

Objectif :

- Segmentation
- Association

3. DOMAINES D'APPLICATION DU DATA MINING

Le Data Mining se répand particulièrement dans les secteurs qui, par leur activité, détiennent de nombreuses informations économiques et comportementales individualisées :

- Vente par correspondance
- Grande distribution
- Téléphonie
- Banque...

Selon le MIT (Massachusetts Institute of Technology) : *le Data Mining est l'une des 10 technologies émergentes qui « changeront le monde » au XXIe siècle.*

Exemple de domaines d'utilisation du DATA MINING :

- 1) Domaine des assurances
 - analyse des clients à "haut risque"
- 2) Services financiers
 - Attribution d'un crédit bancaire
 - Détection de fraude

- Marketing ciblé
- 3) Grande distribution
- Profil de consommateurs
 - Constitution des rayons
 - Marketing ciblé
- 4) Médecine
- Aide au diagnostic
- Etc.




Figure N°5 : Sondage sur les domaines d'application du Data mining (<http://www.kdnuggets.com>, 2011)




Figure N°6: Sondage sur les sujets d'analyse du Data mining (<http://www.kdnuggets.com>, 2012)

La répartition géographique se présente de la manière suivante:

- US/Canada : 38.3%
- Europe : 28.1%
- Asia : 16.3%
- Africa/Middle East : 8.7%
- Latin America : 5.1%
- Australia/NZ : 3.1%

4. PROCESSUS DU DATA MINING

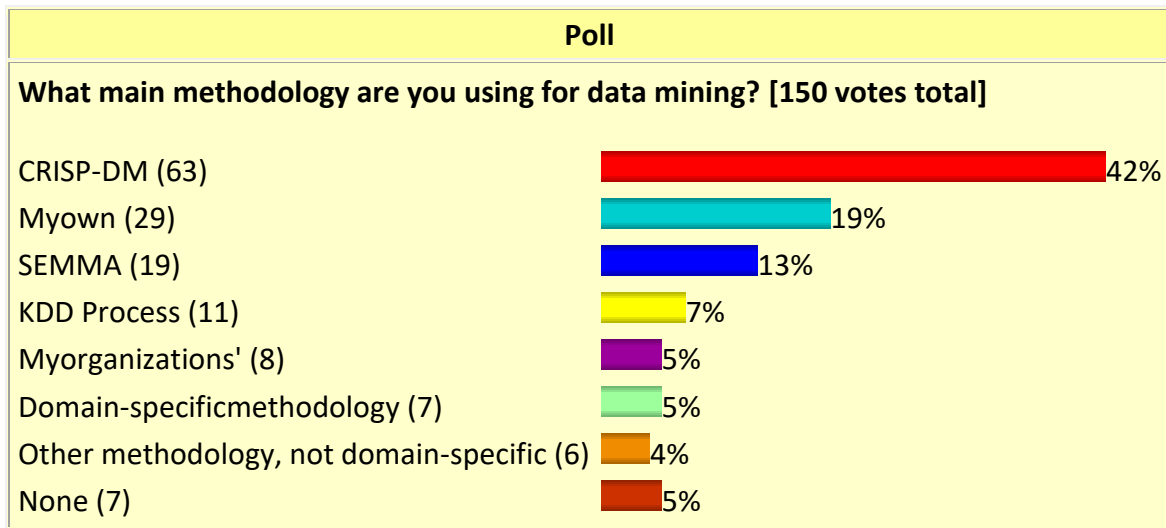


Figure N°7: Sondage sur les méthodologies du Data mining (<http://www.kdnuggets.com>, août 2007)

4.1. La méthodologie CRISP-DM

4.1.1. Généralités

CRISP-DM (Cross Industry Standard Process for Data Mining). Il s'agit d'un Modèle de Processus de **data mining** qui décrit une approche communément utilisée par les experts en data mining pour résoudre les problèmes qui se posent à eux. Des sondages effectués en 2002, 2004, et 2007 montrent qu'il s'agit de la méthode principale utilisée par les spécialistes en Data Mining.

Cette méthode a été créée par un consortium formé des compagnies NCR (spécialiste en DataWarehouses), SPSS (constructeur de logiciels statistiques), et Daimler-Benz (groupe automobile et aéronautique allemand), OHRA (société d'assurances néerlandaise).

Il s'agit de définir une approche rationnelle du Data Mining qui soit indépendante de l'outil informatique utilisé.

CRISP-DM découpe le processus de Datamining en six phases principales:




Figure N°8: Les principales phases du CRISP-DM

La séquence des phases n'est pas rigide, un «va et vient» entre les différentes phases est toujours nécessaire, il dépend de l'issue de chaque phase.

Le cercle extérieur à la figure symbolise la nature cyclique des données elles-mêmes. L'étude Data Mining n'est pas terminée une fois qu'une solution est déployée, les leçons apprises au cours du processus et la solution déployée peuvent déclencher de nouvelles, souvent à davantage de questions ciblées. La suite des processus data mining bénéficieront de l'expérience de précédents.

4.1.2. Phases Principales de la méthodologie CRISP-DM

1 : **Business Understanding** (*Compréhension du métier*)

Cette phase consiste à :

- Énoncer clairement les objectifs globaux du projet et les contraintes de l'entreprise

- Traduire ces objectifs et ces contraintes en un problème de data mining
- Préparer une stratégie initiale pour atteindre ces objectifs.

2 : **Data understanding** (*Compréhension des données*)

Cette phase consiste à :

- Recueillir les données
- Utiliser l'analyse exploratoire pour se familiariser avec les données, commencer à les comprendre et imaginer ce qu'on pourrait en tirer comme connaissance
- Évaluer la qualité des données
- Éventuellement, sélectionner des sous-ensembles intéressants.

3 : **Data preparation** (*Préparation des données*)

Cette phase consiste à :

- Préparer, à partir des données brutes, l'ensemble final des données qui va être utilisé pour toutes les phases suivantes
- Sélectionner les cas et les variables à analyser
- Réaliser si nécessaire les transformations de certaines données
- Réaliser si nécessaire la suppression de certaines données.
- Cette phase fait suite à la compréhension des données. Celle-ci a mis au jour les corrélations, les valeurs aberrantes, les valeurs manquantes : on peut donc faire la préparation.

4 : **Data modeling** (*Modélisation*)

Cette phase consiste à :

- Sélectionner les techniques de modélisation appropriées (souvent plusieurs techniques peuvent être utilisées pour le même problème).
- Calibrer les paramètres des techniques de modélisation choisies pour optimiser les résultats
- Éventuellement revoir la préparation des données pour l'adapter aux techniques utilisées.

5 : **Evaluation** (*Evaluation de la modélisation*)

Cette phase consiste à produire le rapport final :

- Pour chaque technique de modélisation utilisée, évaluer la qualité (la pertinence, la signification) des résultats obtenus
- Déterminer si les résultats obtenus atteignent les objectifs globaux identifiés pendant la phase de compréhension du métier
- Décider si on passe à la phase suivante (le déploiement) ou si on souhaite reprendre l'étude en complétant le jeu de données.

6 : **Deployment** (*Déploiement des résultats obtenus*)

Cette phase est externe à l'analyse du data mining. Elle concerne le maître d'ouvrage.

Cette phase consiste à :

- Prendre les décisions en conséquences des résultats de l'étude de data mining
- Préparer la collecte des informations futures pour permettre de vérifier la pertinence des décisions effectivement mises en œuvre.

4.2. Etude de cas basée sur la méthodologie CRISP-DM

Objectif : Analyser les plaintes des clients dans l'industrie automobile

La garantie de la qualité est une priorité pour tous les constructeurs automobiles. Jochen Hipp de l'Université de Tübingen (Allemagne) et Guido Linder de Daimler Chrysler, ont étudié les phénomènes présents dans les plaintes des clients, émises au sujet d'automobile Daimler Chrysler sous garantie.

1) La phase de compréhension métier

Les objectifs de Daimler Chrysler sont de réduire les coûts associés aux plaintes et d'améliorer la satisfaction des clients. Au travers de conversation avec des ingénieurs de la production, les chercheurs ont été capables de formuler des problèmes métiers spécifiques tels que ceux-ci :

- Y a-t-il des interdépendances entre les plaintes des clients ?
- Est-ce que les plaintes du passé sont liées aux plaintes du futur ?
- Existe-t-il une association entre un certain type de plainte et un garage donné ?

Le projet est d'appliquer des techniques de Datamining appropriées pour essayer de découvrir ces associations, et d'autres éventuellement.

2) La phase de compréhension des données

Les chercheurs ont utilisé un système d'information sur la qualité (QUIS – Quality Information System) de Daimler Chrysler qui contient des informations sur plus de 7 millions de véhicules et qui a une taille d'environ 40 gigabits. Le QUIS contient les détails de production sur la façon et le lieu où un véhicule donné a été construit, incluant en moyenne 30 codes commerciaux pour chaque véhicule. Le QUIS inclut aussi les informations sur les plaintes clients que le garage a fournies sous la forme de plus de 5000 causes potentielles.

Les chercheurs ont insisté sur le fait que la base de données est intelligible pour des non-experts du domaine : les experts des différents départements doivent donc être

systématiquement localisés et consultés ; cette tâche devient plutôt coûteuse. Ils insistent sur le fait que les analystes ne doivent pas sous-estimer l'importance, la difficulté et le coût potentiel de cette phase de départ du processus de Data Mining, et que des raccourcis hasardeux à ce niveau peuvent conduire à des réitérations des phases en amont du processus.

3) La phase de préparation des données

Les chercheurs ont découvert que la base de données, bien que relationnelle offre un accès limité par SQL. Ils ont dû manuellement sélectionner les cas et variables pertinentes.

Ils ont ensuite utilisé un logiciel de data mining, qui a déjà été utilisé dans des projets précédents. Ils ont rencontré à ce niveau beaucoup de problèmes : incompatibilité de format des données d'un algorithme à l'autre. Comme résultats, les données devaient subir encore des traitements pour se conformer aux algorithmes du modèle étudié.

Les chercheurs estiment que l'étape de préparation des données leur a pris plus de temps que celle de la planification.

4) L'étape de modélisation

Le problème soulevé à l'étape No1 étant de déterminer les relations entre les plaintes, les chercheurs ont décidé d'appliquer les techniques suivantes : les réseaux bayesiens, les règles d'association.

5) La phase d'évaluation

La phase d'évaluation a montré que les modèles utilisés sont peu fiables et ne répondent pas aux exigences de l'étape No 1. Ils expliquent cela par la structure de la base de données




6) La phase de déploiement

Les chercheurs ont identifié ce projet comme un projet pilote et ont décidé de ne déployer aucun grand modèle de cette première itération. Après ce projet pilote, ils

ont décidé d'appliquer les enseignements tirés en les intégrant au système d'information de Daimler Chrysler, en vue de diminuer le coût des plaintes.

5. LES PRINCIPAUX LOGICIELS DU DATA MINING

What Analytics, Big Data, Data mining, Data Science software you used in the past 12 months for a real project?[1880 voters]	
Legend: Red: Free/Open Source tools Green: Commercial tools	 % users in 2013  % users in 2012
Rapid-I RapidMiner/RapidAnalytics free edition (737), 30.9% alone	 39.2%  26.7%
R (704), 6.5% alone	 37.4%  30.7%
Excel (527), 0.9% alone	 28.0%  29.8%
Weka / Pentaho (269), 5.6% alone	 14.3%  14.8%
Python with any of numpy/scipy/pandas/iPython... packages (250), 0% alone	 13.3%  14.9%
Rapid-I RapidAnalytics/RapidMiner Commercial Edition (225), 52.4% alone	 12.0%
SAS (202), 2.0% alone	 10.7%  12.7%
MATLAB (186), 1.6% alone	 9.9%  10.0%
StatSoft Statistica (170), 45.9% alone	 9.0%  14.0%
IBM SPSS Statistics (164), 1.8% alone	 8.7%  7.8%
Microsoft SQL Server (131), 1.5% alone	 7.0%  5.0%
Tableau (118), 0% alone	 6.3%  4.4%
IBM SPSS Modeler (114), 6.1% alone	 6.1%  6.8%

KNIME free edition (110), 1.8% alone	 5.9%  21.8%
SAS Enterprise Miner (110), 0% alone	 5.9%  5.8%
Rattle (84), 0% alone	 4.5%
JMP (77), 7.8% alone	 4.1%  4.0%
Orange (67), 13.4% alone	 3.6%  5.3%
Other free analytics/data mining software (64), 3.1% alone	 3.4%  4.9%
Gnu Octave (54), 0% alone	 2.9%
Revolution Analytics R Enterprise (53), 1.9% alone	 2.8%  1.4%
Predixion Software (51), 43.1% alone	 2.7%  0.4%
KNIME Professional (46), 4.3% alone	 2.4%
Revolution Analytics R free edition (46), 2.2% alone	 2.4%
IBM Cognos (45), 2.2% alone	 2.4%  2.0%
Other commercial analytics/data mining/data science software (45), 0% alone	 2.4%  4.0%
QlikView (45), 2.2% alone	 2.4%
Salford SPM/CART/MARS/TreeNet/RF (42), 26.2% alone	 2.2%  1.1%
Mathematica (39), 0% alone	 2.1%  2.9%
Stata (39), 2.6% alone	 2.1%  1.9%
KXEN (35), 54.3% alone	 1.9%  1.8%
Miner3D (34), 41.2% alone	 1.8%  2.4%

SAP (including BusinessObjects/Sybase/Hana) (27), 3.7% alone	 1.4%  0.9%
TIBCO Spotfire / S+ / Miner (26), 3.8% alone	 1.4%  4.6%
C4.5/C5.0/See5 (21), 0% alone	 1.1%  1.6%
Bayesia (19), 15.8% alone	 1.0%  1.8%
Oracle Data Miner (19), 5.3% alone	 1.0%  4.4%
Zementis (17), 41.2% alone	 0.9%  1.8%
XLSTAT (16), 0% alone	 0.9%  0.9%
F# (14), 14.3% alone	 0.7%  0.6%
RapidInsight/Veera (9), 0% alone	 0.5%  0.6%
Teradata Miner (9), 0% alone	 0.5%  0.5%
Lavastorm (8), 25.0% alone	 0.4%
WordStat (7), 0% alone	 0.4%  0.4%
Angoss (6), 16.7% alone	 0.3%  0.9%
11 Ants Analytics (5), 0% alone	 0.3%  0.5%
Alteryx (5), 0% alone	 0.3%
MegaputerPolyanalyst/TextAnalyst (2), 0% alone	 0.1%

Figure N°9: Sondage sur les principaux logiciels de Data mining (<http://www.kdnuggets.com>, Mai 2013)

6. EXEMPLES D'ARCHIVES DE DONNEES SUR INTERNET

Il existe des archives de données pour tester les tâches de datamining :

- The UCI Repository of Datasets: <https://archive.ics.uci.edu/datasets>
- Kaggle: <https://www.kaggle.com/datasets>
- Hugging Face: <https://huggingface.co/datasets>