

PRE-TRAITEMENT DES DONNÉES

1. POURQUOI PRÉTRAITER LES DONNÉES ?

La qualité des données constituent un élément fondamental au Data Mining. La plupart des données brutes emmagasinées dans les bases de données ne sont pas traitées, sont incomplètes, et bruitées.

Par exemple une base de données peut contenir :

- Des champs obsolètes ou inutiles
- Des enregistrements avec des données manquantes
- Des exceptions
- Des données dont le format ne répond pas au modèle de l'exploration
- Des données incohérentes : nommage, codage
- Des données incomplètes : valeurs manquantes, données simplifiées
- Des données bruitées : erreurs et exceptions

Les résultats de la fouille dépendent de la qualité des données.

La préparation des données est une étape importante du Data Mining : D'après Dorian Pyle (Data Preparation for Data Mining), elle occupe **environ 60% au moins** du temps et de l'effort consacrés à l'ensemble du processus.

Pour que les données soient utiles à l'objectif de l'exploration, il faut les travailler.

Les principales étapes dans le prétraitement des données :

- Nettoyage
- Intégration
- Transformation
- Réduction
- Discrétisation

2. DONNEES MANQUANTES

Le manque de données n'est pas une bonne chose. Plus on dispose de données, en général mieux il vaut.

- Données non disponibles
 - certains attributs n'ont pas de valeur
- Causes :
 - mauvais fonctionnement de l'équipement
 - incohérences avec d'autres données et donc supprimées
 - non saisies car non ou mal comprises
 - considérées peu importantes au moment de la saisie

- Comment gérer les données manquantes

Ces données doivent être inférées


Comment remplir les trous ?

- Ignorer l'enregistrement :
Peu efficace quand le pourcentage de valeurs manquantes est élevé
- Compléter manuellement les données :
Laborieux ou infaisable
- Utiliser une constante globale :
ex : « inconnue », une nouvelle catégorie ?
- Utiliser la moyenne de l'attribut (variable numérique) ou le mode (variable modale)
- Utiliser la moyenne de l'attribut pour la même classe :
Mieux
- Utiliser la valeur la plus probable :
Formule Bayésienne ou arbre de décision


3. DONNEES BRUITEES

- Bruit : erreur ou variance aléatoire d'une variable mesurée
- Causes :
 - Instrument de mesure défectueux
 - Problème de saisie

- Problème de transmission
- Limitation technologique
- Incohérence dans les conventions de nommage
- Autres problèmes :
 - enregistrement dupliqués
 - données incomplètes
 - données incohérentes
- Correction du bruit
 - Méthode numérique de détection des points isolés
 - Clustering :



- Inspection humaine et informatique combinée :
Détection des valeurs suspectes et vérification humaine
- Régression :
Lisser les données par des fonctions de régression



4. INTEGRATION DES DONNEES

- Intégration des données :
Combinaison de différentes sources en une seule
- Intégration des schémas :
 - intégrer les méta-données de différentes sources
 - problème de nommage : identifier les différents noms des mêmes données réelles, ex : num_client ≡ client_id
- Détecter et résoudre les conflits de valeurs
 - pour les mêmes entités réelles, les valeurs des attributs provenant de sources différentes sont différentes
 - causes : représentation différentes, échelles différentes, ex : cm et pouces

5. GESTION DE LA REDONDANCE

- fréquente lors de l'intégration de plusieurs sources de données
 - le même attribut peut avoir des noms différents
 - un attribut peut être déduit d'un autre
- peut être détectée par des analyses de corrélation

6. TRANSFORMATION DES DONNEES

La transformation peut consister en l'un des traitements suivants :

- Lissage : réduire le bruit dans les données
- Agrégation : simplification, construction de cubes de données
- Généralisation : hiérarchie de concepts
- Normalisation : mise à l'échelle pour avoir un petit intervalle spécifié

- **min-max**

X – valeur originale du champ

X^* - valeur normalisée

$$X^* = \frac{X - \min(X)}{\max(X) - \min(X)}$$

Après normalisation, la valeur normalisée devrait se retrouver dans l'intervalle [0,1]

- Standardisation

z-score

X – valeur originale

X^* - valeur standardisée

$\sigma(X)$ – écart type

$$X^* = \frac{X - \text{moyenne}(X)}{\sigma(X)}$$

Rappels

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

$$\bar{x} = \frac{\sum_{i=1}^N x_i}{N}$$

7. REDUCTION DES DONNEES

- La fouille de données peut être très longue sur les données complètes
- Réduction des données :
 - obtenir une représentation réduite du jeu de données, plus petite en volume, mais qui produit les mêmes (ou presque) résultats analytiques
- Stratégies
 - Agrégation par cubes de données
 - Réduction de dimension
 - Réduction de numérosité
 - Discrétisation et génération de hiérarchies de concepts

Exemple

		Attributs							Attributs				
		A1	A2	A3	...	A126			A1	A3	...	A115	
Transactions	T1						?	T1					
	T2							T4					
	T3							...					
	T4							T1456					
	...												
	T2000												

8. EXERCICES D'APPLICATION

Exercice No 1

Observez le tableau ci-dessous et faites ressortir les problèmes, incohérences, etc.

ID du client	Code postal	Sexe	Revenu	Age	État civil	Montant de la transaction
1001	10048	M	75000	C	M	5000
1002	J2S7K7	F	-40000	40	V	4000
1003	90210		10000000	45	C	7000
1004	6269	M	50000	0	C	1000
1005	55101	F	999999	30	D	3000

Exercice No 2

Considérer l'ensemble de données «churn» à téléchargeable du site de *Machine Learning Repository*.

- 1) Vérifier s'il y a des valeurs manquantes pour une variable données
- 2) Comparez le champ «area code» et «state». Quelles incohérences flagrantes relevez-vous ?
- 3) Transformez l'attribut «day minutes» par normalisation min-max. Vérifiez par une courbe si toutes les valeurs sont comprises entre l'intervalle [0,1]
- 4) Transformez l'attribut «night minutes» par standardisation. En utilisant une courbe, donnez l'intervalle des valeurs après standardisation