

CLASSIFICATION

1. Généralités

1.1. Qu'est-ce que la classification ?

- Méthode de raisonnement à partir de cas : prendre des décisions en recherchant un ou des cas similaires déjà résolus.
- On a une collection d'enregistrements :
 - Chaque enregistrement contient un ensemble d'attributs, l'un des attributs représente la classe
- Trouver un modèle pour l'attribut «classe» comme une fonction des valeurs des autres attributs
- Objectifs :
 - Appliquer le modèle aux enregistrements inconnus pour prédire de manière précise leur classe
- L'ensemble des données peut être divisé en deux parties :
 - L'ensemble d'apprentissage utilisé pour construire le modèle
 - L'ensemble de test pour vérifier la précision du modèle

1.2. Processus de la classification

La classification est un processus à deux étapes :

Etape 1 : Construction du modèle

- A partir de l'ensemble d'apprentissage (*training set*)
- Chaque instance est supposée appartenir à une classe prédéfinie

- La classe d'une instance est déterminée par l'attribut dit "de décision"
- L'ensemble des instances d'apprentissage est utilisé dans la construction du modèle

Etape 2 : Utilisation du modèle

- Tester la précision du modèle et l'utiliser dans la classification de nouvelles données
- Le modèle est représenté par des règles de classification, arbres de décision, formules mathématiques, ...

1.3. Validation de la Classification

Estimation des taux d'erreurs:

Taux d'erreur = pourcentage de tests incorrectement classés par le modèle

Partitionnement:

- Apprentissage et test
- Utiliser 2 ensembles indépendants : ensemble d'apprentissage (2/3), ensemble test (1/3)

Validation croisée

- Diviser les données en k sous-ensembles
- Utiliser k-1 sous-ensembles comme données d'apprentissage et un sous-ensemble comme données test

1.4. Domaines d'application

Les exemples de tâches de classification se rencontrent dans presque tous les domaines :

- Banque :
 - Déterminer le niveau de risque d'une demande de crédit bancaire
 - Déterminer si une transaction par carte de crédit est une fraude
- Marketing direct
 - profils des consommateurs
- grande distribution
 - classement des clients
- Éducation :
 - Allouer un groupe pédagogique à un étudiant en tenant compte de ses besoins
- Médecine
 - Diagnostiquer une maladie (malade/non malade)
- Droit
 - Déterminer si un testament est vrai ou faux
- Sécurité nationale
 - Déterminer si certains comportements financiers ou individuels indiquent des menaces terroristes
- Etc.

Exemple de classification :

Etant donné les caractéristiques d'un certain nombre de clients, il faut catégoriser le client **David** dans l'une des deux classes N ou O

Client	Age	Salaire	Nbre de carte de crédit	Loyal
Jean	35	35000	3	N
Rachèle	22	50000	2	O
Anne	63	200000	1	N
Thomas	59	170000	1	N
Nathalie	25	40000	4	O
David	37	50000	2	?

1.5. Méthodes de Classification

Quelques méthodes

- Méthode K-NN (K- Nearest Neighbors, K plus proches voisins)
- Arbres de décision
- Réseaux de neurones
- Classification bayésienne
- Algorithmes génétiques
- SVM (Support Vector Machines)

Evaluation des méthodes de classification

- Taux d'erreur
- Temps d'exécution (construction, utilisation)
- Robustesse (bruit, données manquantes,...)
- Extensibilité
- Interprétabilité
- Simplicité

2. La méthode des plus proches voisins (kppv)

K plus proches voisins (en anglais : K-nearest neighbors, K-nn)

2.1. Principes de l'algorithme

- Pas d'étape d'apprentissage : construction d'un modèle à partir d'un échantillon d'apprentissage
- Modèle = échantillon d'apprentissage + fonction de distance + fonction de choix de la classe en fonction des classes des voisins les plus proches

- Objectif : affecter une classe à une nouvelle instance
- Donnée : un échantillon de m enregistrements classés $(x, c(x))$
- Entrée : un enregistrement y
 - Déterminer les k plus proches enregistrements de y
 - Combiner les classes de ces k exemples en une classe c
- Sortie : la classe de y c'est-à-dire $c(y)=c$

2.2. Algorithme kNN : sélection de la classe

DEBUT

POUR CHAQUE $((x', c) \in D)$ **FAIRE**

Calculer la distance $\text{dist}(x, x')$

FINPOUR

POUR CHAQUE $\{x' \in kpp\}$ **FAIRE**

Compter le nombre d'occurrence de chaque classe

FINPOUR

Attribuer à x la classe la plus fréquente

FIN

Solution simple :

Rechercher le cas le plus proche et prendre la même décision (Méthode 1-NN).

Combinaison des k classes :

- Heuristique : $k = \text{nombre d'attributs} + 1$
- Vote majoritaire : prendre la classe majoritaire.
- Vote majoritaire pondéré : chaque classe est pondérée.

Le poids de $c(x_i)$ est inversement proportionnel à la distance $d(y, x_i)$.


Remarque:

Étant donné que la méthode K-nn dépend de la mesure de distance, il est recommandé que les données d'entrée soient normalisées avant de procéder à la construction du modèle.


Confiance : Définir une confiance dans la classe attribuée = rapport entre les votes gagnants et le total des votes.

2.3. Illustration

deux classes, $k = 1$



deux classes, $k = 3$



2.4. Mesure de distance entre les individus

Le choix de la mesure de distance entre individus dépend des données étudiées et des objectifs.

Le choix de la distance est primordial au bon fonctionnement de la méthode

2.4.1. Propriétés de la distance:

- $d(A,B) \geq 0$
- $d(A,A)=0$
- $d(A,B)=d(B,A)$
- $d(A,B) \leq d(A,C) + d(B,C)$

2.4.2. Distance entre numériques

Soient $x=(x_1, x_2, \dots, x_m)$ et $y=(y_1, y_2, \dots, y_m)$

- o Distance Euclidienne : le type de distance le plus couramment utilisé. Il s'agit d'une distance géométrique dans un espace multidimensionnel.

$$d_{\text{Euclidienne}}(x, y) = \sqrt{\sum_{i=1}^m (x_i - y_i)^2}$$

- o Distance Euclidienne au carré : Permet de "sur-pondérer" les objets atypiques (éloignés), en élevant la distance euclidienne au carré.

$$d_{\text{EuclidCarré}}(x, y) = \sum_{i=1}^m (x_i - y_i)^2$$

- o Distance du City-block (Manhattan) : cette distance est simplement la somme des différences entre les dimensions.

$$d_{\text{Manhattan}}(x, y) = \sum_{i=1}^m |x_i - y_i|$$

- o Distance de Minkowski

$$d_{\text{Minkowski}}(x, y) = \sqrt[q]{\sum_{i=1}^m |x_i - y_i|^q}$$

$q = 1$: distance de manhattan

$q = 2$: distance euclidienne

2.4.3. Distance entre nominaux

- Données binaires : 0 ou 1. On choisit $d(0,0)=d(1,1)=0$ et $d(0,1)=d(1,0)=1$.
- Données énumératives : la distance vaut 0 si les valeurs sont égales et 1 sinon.
- Données énumératives ordonnées : elles peuvent être considérées comme des valeurs énumératives mais on peut également définir une distance utilisant la relation d'ordre.

Exemple: Si un champ prend les valeurs A, B, C, D et E, on peut définir la distance en considérant 5 points de l'intervalle $[0,1]$ avec une distance de 0.2 entre deux points successifs, on a alors $d(A,B)=0.2$; $d(A,C)=0.4$; ... ; $d(D,E)=0.2$.

2.5. Exercice d'application :

Appliquer le vote simple et le vote pondéré afin de classer l'individu David du tableau de la section 1.4. Utiliser la distance euclidienne avec $K=3$


3. Les méthodes d'induction d'arbre de décision

3.1. Généralités

- Génération d'arbre de décision à partir de données
- Arbre de décision = représentation graphique d'une procédure de classification
- Chaque nœud interne = un test sur un attribut (des attributs)
- Chaque branche d'un nœud = résultat d'un test sur un attribut
- Chaque feuille = classe donnée
- Une règle est générée pour chaque chemin de l'arbre (de la racine à une feuille)
- Les paires attribut-valeur d'un chemin forment une conjonction
- Le nœud terminal représente la classe prédite

Exemple : Détection de fraudes fiscales

	énumératif	énumératif	numérique	classe
'd	Ristourne	Situation famille	Impôt revenu	Fraude
1	Oui	Célibat.	125K	Non
2	Non	Marié	100K	Non
3	Non	Célibat.	70K	Non
4	Oui	Marié	120K	Non
5	Non	Divorcé	95K	Oui
6	Non	Marié	60K	Non
7	Oui	Divorcé	220K	Non
8	Non	Célibat.	85K	Oui
9	Non	Marié	75K	Non
10	Non	Célibat.	90K	Oui



SI Ristourne = Oui

ALORS Non

SI Ristourne = Non

ET Situation in {Célibat., Divorcé} **ET** Impôt < 80K

ALORS Non

SI Ristourne = Non

ET Situation in { Célicat., Divorcé } **ET** Impôt >= 80K

ALORS Oui

SI Ristourne = Non

ET Situation in {Marié}

ALORS Non

Les phases de génération d'un arbre de décision

- 1) Au départ, toutes les instances d'apprentissage sont à la racine de l'arbre
- 2) Sélectionner un attribut et choisir un test de séparation (split) sur l'attribut, qui sépare le mieux les instances. La sélection est basée sur une heuristique ou une statistique
- 3) Partitionner les instances entre nœuds fils suivant la satisfaction des tests logiques
- 4) Traiter chaque nœud fils de façon récursive
- 5) Répéter jusqu'à ce que tous les nœuds. Un nœud courant est terminal si :
 - a. Il n'y a plus d'attributs disponibles
 - b. Le nœud est «pur», i.e toutes les instances appartiennent à une seule classe
 - c. Le nœud est «presque pur», i.e. la majorité des instances appartiennent à une seule classe (ex : 95%)
 - d. Nombre minimum d'instances par branche (Ex : algorithme C5 évite la croissance de l'arbre, k=2 par défaut)
- 6) Étiqueter le nœud terminal par la classe majoritaire


Exemples d'algorithmes de génération d'arbre de décision

- Algorithmes basés sur l'apprentissage automatique : ID3, C4.5
- Algorithme basée sur la statistique : CART
- Algorithme basée sur la reconnaissance des formes : CHAID


3.2. Partitionnement des données

Une étape importante dans la construction d'un arbre de décision consiste à trouver la condition appropriée pour le partitionnement des données

- Le cas des attributs catégoriels
 - La condition de test peut être exprimée comme une paire «attribut – valeur» de la forme $(A = v ?)$, dont le résultat est Vrai/Faux, ou bien une question sur la valeur d'un attribut de la forme $(a ?)$




- Le cas des attributs continus
 - Le test peut être exprimé en terme de décision binaire de la forme $(A < v ?)$ dont le résultat est Vrai/Faux, ou bien comme une requête dont le résultat sont des intervalles de la forme $v_i \leq A \leq v_{i+1}$, pour $i = 1, 2, \dots, k$
 - Illustration



- Cas des attributs nominaux

- Chaque partition a un sous-ensemble de valeurs
- Partition « multi branche » : on utilise autant de partition qu'il y a de valeurs pour l'attribut
- Partition binaire : on divise les valeurs en deux sous-ensembles



Quelques mesures de sélection d'attributs

Les différents algorithmes n'utilisent pas le même critère de sélection d'attribut (critère de branchement)

- Indice de Gini : CART, SPRINT
 - o On choisit l'attribut qui maximalise l'indice Gini
- Gain d'information: ID3, C4.5
 - o On choisit l'attribut qui maximalise la réduction d'entropie
- Table de contingence statistique χ^2 (Indice de corrélation χ^2) : CHAID
 - o On mesure la corrélation entre chaque attribut et chaque classe (représentée par l'attribut décisionnel). On choisit l'attribut avec la plus grande corrélation

4. Indice de Gini

Définition :

L'indice de Gini pour un nœud t :

$$GINI(t) = 1 - \sum_j [p(j|t)]^2$$

$P(j|t)$ – fréquence relative de la classe j au nœud t

Si S est pur (classe unique), $Gini(S)=0$

Plus l'indice de Gini est bas plus le nœud est pur

Le calcul de Gini nécessite une Matrice de dénombrement :

Exemples de calcul de l'indice de GINI :

C1	0
C2	6

$$P(C1) = 0/6 = 0 \quad p(C2) = 6/6 = 1$$

$$GINI = 1 - p(C1)^2 - p(C2)^2 = 1 - 0 - 1 = 0$$

C1	1
C2	5

$$P(C1) = 1/6 \quad p(C2) = 5/6$$

$$GINI = 1 - (1/6)^2 - (5/6)^2 = 0.278$$

C1	2
C2	4

$$P(C1) = 2/6 \quad p(C2) = 4/6$$

$$GINI = 1 - (2/6)^2 - (4/6)^2 = 0.444$$

Erreur de classification au nœud t:

$$Erreur(t) = 1 - \max P(i|t)$$

Partitionnement à base de l'indice de GINI

Quand un nœud p est divisé en k partitions (nœud fils), la qualité de la partition est donnée par la formule :

$$GINI_{split} = \sum_{i=1}^k \frac{n_i}{n} GINI(i)$$

Où :

n_i - nombre d'enregistrement à l'enfant i

n – nombre d'enregistrement au nœud p

On choisit le point de branchement (**split-point**) qui minimise l'indice de GINI

EXERCICE D'APPLICATION

Ensemble d'apprentissage

ID	Age	Type_voit	Risque
0	23	Familiale	Élevé
1	17	Sport	Élevé
2	43	Sport	Élevé
3	68	Familiale	Faible
4	32	Camion	Faible
5	20	Familiale	Élevé

Dessiner l'arbre de décision en utilisant l'indice de GINI

5. Gain d'information

Sélectionner l'attribut avec le plus grand gain d'information

5.1. Notion d'entropie

L'entropie, ou l'information nécessaire pour classifier les instances dans les sous-arbres

Entropie mesure l'impureté de S

L'entropie à un nœud t :

$$Entropy(t) = - \sum_j p(j|t) \log p(j|t)$$

$p(j|t)$ = fréquence relative de la classe j au nœud t

L'entropie mesure l'homogénéité d'un nœud

- Maximum ($\log n_c$) quand les enregistrements sont uniformément distribués à travers toutes les classes

- n_c : nombre de classes
- Minimum (0.0) quand tous les enregistrements appartiennent à une classe, entraînant moins d'impureté

Le calcul à base d'entropie est similaire à celui de l'indice de GINI

Exemples de calcul

C1	0
C2	6

$$p(C1) = 0/6 \quad p(C2) = 6/6 = 1, \text{ Entropy} = -0 \log 0 - 1 \log 1 = -0-0=0$$

C1	1
C2	5

$$p(C1) = 1/6 \quad p(C2) = 5/6, \text{ Entropy} = -(1/6) \log(1/6) - (5/6) \log(5/6) = 0.65$$

C1	2
C2	4

$$p(C1) = 2/6 \quad p(C2) = 4/6; \text{ Entropy} = -(2/6) \log(2/6) - (4/6) \log(4/6) = 0.92$$

5.2. Partitionnement à base du gain d'information

$$GAIN_{split} = Entropy(p) - \left(\sum_{i=1}^k \frac{n_i}{n} Entropy(i) \right)$$

p – nœud parent avec n enregistrements scindés en k partitions

n_i – nombre d'enregistrements dans la partition i

$GAIN_{split}$ – mesure de la réduction en entropie, obtenue à cause de la partition

On choisit le partitionnement qui permet d'atteindre la plus grande réduction (maximise le gain)

Partitionnement à base du taux de gain d'information

$$GainRATIO_{split} = \frac{GAIN_{split}}{SplitINFO};$$

$$SplitINFO = - \sum_{i=1}^k \frac{n_i}{n} \log \frac{n_i}{n}$$

Ajuster le gain d'information par l'entropie du partitionnement (SplitINFO). Une entropie élevée de partitionnement (nombre élevé de petites partitions) est pénalisée

Utilisé dans l'algorithme C4.5

Conçu pour corriger les faiblesses du gain d'information

Erreur de classification

- Erreur de classification à un nœud t
 $Erreur(t) = 1 - \max P(i|t)$
- Maximum ($1-1/n_c$) quand les enregistrements sont uniformément distribués à travers toutes les classes, entraînant moins d'information intéressante
- Minimum (0.0), quand tous les enregistrements appartiennent à une classe, entraînant plus d'information intéressante

Exemples de calcul d'erreur de classification

C1	0
C2	6

$$p(C1) = 0/6 \quad p(C2) = 6/6 = 1, \text{ Erreur} = 1 - \max(0,1) = 1 - 1 = 0$$

C1	1
C2	5

$$p(C1) = 1/6 \quad p(C2) = 5/6, \quad \text{Erreur} = 1 - \max(1/6, 5/6) = 1 - 5/6 = 1/6$$

C1	2
C2	4

$$p(C1) = 2/6 \quad p(C2) = 4/6; \quad \text{Erreur} = 1 - \max(2/6, 4/6) = 1 - 4/6 = 1/3$$

Avantages et inconvénients des arbres de décision

- Avantages
 - Compréhensible pour tout utilisateur (lisibilité du résultat – règle – arbre)
 - Justification de la classification d'une instance (racine -> feuille)
 - Tout type de données
 - Robuste au bruit et aux valeurs manquantes
 - Attributs apparaissent dans l'ordre de pertinence
 - Classification rapide (parcours d'un chemin dans un arbre)
 - Outils disponibles dans la plupart des environnements de Datamining
- Inconvénients
 - Sensibles au nombre de classes : performances se dégradent
 - Évolutivité dans le temps : si les données évoluent dans le temps, il est nécessaire de relancer la phase d'apprentissage

6. Mesures de performance en classification

Pour mesurer la performance d'un classifieur, plusieurs critères existent. On se base souvent sur la matrice de confusion

1.1. Classification binaire

Matrice de confusion

Classes d'origine	Classes d'affectation	
positif	TP (classé comme positif)	FN (classé comme négatif)
négatif	FP (classé comme positif)	TN (classé comme négatif)

Différentes mesures

Mesure	Formule	Explication
Exactitude	$\frac{TP + TN}{TP + TN + FP + FN}$	Taux de bonne classification. (Effectivité générale du classifieur)
Précision	$\frac{TP}{TP + FP}$	Taux d'identification des éléments classés « positifs » La Précision (P) détermine le pourcentage de documents pertinents restitués pour une requête donnée
Rappel (Sensibilité)	$\frac{TP}{TP + FN}$	Taux d'identification des éléments appartenant à la classe « positif » Le Rappel calcule le pourcentage de documents pertinents restitués par rapport au nombre total des documents pertinents pour cette même requête

Spécificité	$\frac{TN}{TN + FP}$	Taux d'identification des éléments appartenant à la classe « négatif »
F-score	$\frac{(1+\beta^2)*Précision*Rappel}{((\beta^2*Précision)+Rappel))}$ avec β $= 1 \Rightarrow$ $= \frac{2*Précision*Rappel}{Précision+Rappel}$ $= 2 * \left[\frac{1}{Rappel} + \frac{1}{Précision} \right]$	La F-mesure est la moyenne harmonique du Rappel et de la Précision

Un système de recherche d'information est efficace quand le Rappel et la Précision sont proches de 1.

1.2. Classification multi-classe

Matrice de confusion

Classe d'origine	Classes d'affectation		
	c₁		c_n
c₁	n ₁₁		n _{1m}
.....			
c_n	n _{m1}		n _{mm}

n_{ij} – nombre de cas de la classe c_i affectés à tort à la classe c_j

Ainsi, le nombre d'affectations correctes est :

$$S = \sum_{i=1}^m n_{ii}$$

Le taux d'erreur est :

$$E = 1 - \frac{\sum_{i=1}^m n_{ii}}{\sum_{i=1}^m \sum_{j=1}^m n_{ij}}$$

TP SUR LA CLASSIFICATION

Dessiner l'arbre de décision en utilisant le gain d'information. Tester votre résultat avec les logiciels WEKA et PYTHON

ID	age	revenue	étudiant	Etat_civil	Achète_ordinateur
1	<=30	élevé	non	célibataire	non
2	<=30	élevé	non	marié	non
3	31..40	élevé	non	célibataire	oui
4	>40	moyen	non	célibataire	oui
5	>40	bas	oui	célibataire	oui
6	>40	bas	oui	marié	non
7	31..40	bas	oui	marié	oui
8	<=30	moyen	non	célibataire	non
9	<=30	bas	oui	célibataire	oui
10	>40	moyen	oui	célibataire	oui
11	<=30	moyen	oui	marié	oui
12	31..40	moyen	non	marié	oui
13	31..40	élevé	oui	célibataire	oui
14	>40	moyen	non	marié	non