

CLUSTERING (SEGMENTATION)

1. Introduction

1.1. Qu'est-ce que le clustering ?

- Organisation des données en groupes (clusters) de façon à ce que les données similaires soient dans le même groupe
- Apprentissage non supervisé. Les classes sont inconnues

1.2. Qualité d'un clustering

- Une bonne méthode de clustering produira des clusters d'excellente qualité avec : similarité intra-classe importante et similarité inter-classe faible
- La qualité d'un cluster dépend de : la mesure de similarité, l'implémentation de la mesure de similarité
- La qualité d'une méthode de clustering est évaluée par sa capacité à découvrir certains ou tous les patterns cachés

1.3. Problématique du clustering

- Nature des observations : Données binaires, textuelles, numériques, arbres, ... ?
- Notion de similarité (ou de dissimilarité) entre observations
- Définition d'un cluster
- Evaluation de la validité d'un cluster
- Nombre de clusters pouvant être identifiés dans les données
- Quels algorithmes de clustering ?
- Comparaison de différents résultats de clustering

1.4. Applications

1) Marketing :

- grouper des consommateurs selon leur comportement (en terme d'achats / de clics)
- géo marketing : grouper des consommateurs selon diverses données (habitat, âge, nb d'enfants, revenus...)

2) Biologie :

- classification du vivant d'après certaines caractéristiques

3) Assurance :

- grouper selon le profil de risques
- grouper selon profil de comportement (fraude/non fraude)

4) Tremblements de terre :

- grouper des épicentres pour repérer des zones dangereuses

5) web

- grouper des modes d'accès à certaines pages (par quel chemin arrive-t-on à telle page?)

6) Autres exemples

- Grouper les gens de taille semblable pour l'habillement: "small", "medium", "large", "Extra large"
- Etant donné une collection de textes, on peut les organiser selon leur similarité pour former une hiérarchie de sujet
- Le clustering est l'une des techniques de data mining les plus utilisées

Dans presque tous les "e": médecine, psychologie, botanique, sociologie, biologie, archéologie, marketing, assurance, bibliothèque, etc.

1.5. Types de données et structures de données

1.5.1. Les types de données

- Continue sur un intervalle : Exemple : poids, taille
- Binaire
- Nominale : Il s'agit de la généralisation des valeurs binaires : plus de 2 états
exemple : couleur (bleu, blanc, ...)
- Ordinale
- A échelle variable : ex : croissance optimale des bactéries, durée de la radioactivité
- Mixte

1.5.2. Structures de données et mesure de dissimilarité

- Matrice de données

$$\begin{bmatrix} x_{11} & \dots & x_{1f} & \dots & x_{1p} \\ \dots & \dots & \dots & \dots & \dots \\ x_{i1} & \dots & x_{if} & \dots & x_{ip} \\ \dots & \dots & \dots & \dots & \dots \\ x_{n1} & \dots & x_{nf} & \dots & x_{np} \end{bmatrix}$$

- Matrice de distance (ou de dissimilarité)

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ \vdots & \vdots & \vdots & \ddots & \\ d(n,1) & d(n,2) & \vdots & \ddots & 0 \end{bmatrix}$$

- Mesure de dissimilarité: plus la mesure est faible plus les points sont similaires
- Mesure de similarité : plus la mesure est grande, plus les points sont similaires

La qualité d'un cluster g dépend de la mesure de similarité. La mesure de similarité dépend du type de donnée

1.6. Evaluation de la Qualité d'un clustering

1.6.1. Caractéristiques d'un cluster


Chaque cluster C_k est caractérisé par :

- Son centre de gravité : $\mu_k = \frac{1}{N_k} \sum_{x_i \in C_k} x_i$ avec $N_k = \text{card}(C_k)$
- Son inertie : $J_k = \sum_{x_i \in C_k} d^2(x_i, \mu_k)$

L'inertie d'un cluster mesure la concentration des points du cluster autour du centre de gravité. Plus cette inertie est faible, plus petite est la dispersion des points du centre de gravité

1.6.2. Inertie inter-cluster :

Les centres de gravité des clusters forment eux aussi un nuage de points caractérisé par l'inertie inter-cluster. L'inertie inter-cluster mesure donc "l'éloignement" des centres des clusters entre eux. Plus cette inertie est grande, plus les clusters sont bien séparés.




On désigne par inertie inter-cluster, le terme :

$$J_w = \sum_k \sum_{x_i \in C_k} d^2(x_i, \mu_k) = \sum_k J_k$$

1.6.3. Comment obtenir une bonne partition ?

Il faut minimiser l'inertie intra-cluster et maximiser l'inertie inter-cluster

Illustration:



1.7. Approches de clustering

Différentes approches sont possibles:

- Clustering hiérarchique
 - Clustering hiérarchique ascendant et variantes
 - Clustering hiérarchique descendant
- Clustering par partitionnement
 - Algorithme des K-moyennes et variantes
 - Clustering flou
 - ...
- Clustering par modélisation
 - Notion de modèles de mélange
 - Algorithmes EM et variants

La qualité d'une méthode peut aussi être mesurée par sa capacité à trouver quelques ou tous les motifs intéressants

2. Clustering hiérarchique

2.1. Introduction

On a une hiérarchie des groupes de données représentée par un dendrogramme

Un dendrogramme est un arbre binaire de groupes

Le nombre de groupes peut être choisi post-hoc

On coupe horizontalement le dendrogramme à un niveau précis pour obtenir le nombre de groupes choisi

Méthode hiérarchique descendante (Division)

- Commencer avec un groupe contenant toutes les données
- Séparer les groupes en plus petits groupes jusqu'à ce que chaque groupe ne contienne plus qu'un exemple

Méthode hiérarchique ascendante (Agglomération)

La méthode la plus communément utilisée

- Commencer avec des groupes d'un exemple
- Combiner les groupes jusqu'à ce qu'il n'y ait plus qu'un seul groupe (contenant toutes les données)

2.2. Méthode hiérarchique ascendante

2.2.1. Algorithme

ClusteringAgglomeratif(D,k)

$C \leftarrow \{C_i = \{x_i\} \mid x_i \in D\}$ // Chaque point dans un cluster différent

$\Delta \leftarrow \{d(x_i, x_j) : x_i, x_j \in D\}$ // Calculer la matrice de distance

Repeat

Determiner la paire de clusters les plus proches l'un de l'autre, $C_i, C_j \in C$

$C_{ij} \leftarrow C_i \cup C_j$ // Fusionner les clusters

$C \leftarrow (C \setminus \{C_i, C_j\}) \cup \{C_{ij}\}$ // Mise à jour du clustering

Mettre à jour la matrice de distance Δ en fonction du nouveau clustering

Until $|C| = k$

2.2.2. Comment construire les groupes?

- Lien simple (*Simple linkage*)

- La distance entre 2 groupes G1 et G2 est: $\text{Min}(\text{Distance}(x,y))$, où x est un élément de G1 et y est un élément de G2
- On calcule les distances entre tous les groupes en utilisant une matrice des distances (n groupes $\Rightarrow$ matrice nxn)
- Les groupes qui sont les plus proches sont combinés

■ Lien complet (*Complete linkage*)

- La distance entre 2 groupes G1 et G2 est: $\text{Max}(\text{Distance}(x,y))$, où x est un élément de G1 et y est un élément de G2
- On calcule les distances entre tous les groupes en utilisant une matrice des distances (n groupes $\Rightarrow$ matrice nxn)
- Les groupes qui sont les plus éloignés sont combinés

■ Lien moyen (*Average linkage*)

- La distance entre 2 groupes est définie comme la distance moyenne entre toutes les paires d'éléments des 2 groupes
- Elle est calculée de la manière suivante:

La distance entre un groupe G1 et un groupe G2 est $1/(mn) \sum \text{distance}(x,y)$
pour x dans G1 et y dans G2, $|G1| = n$ et $|G2| = m$

- Les groupes qui sont les plus proches sont combinés

2.2.3. Exemple : lien simple

En se basant sur la matrice de distance ci-après, réalisez le clustering hiérarchique ascendant en utilisant le principe de lien simple.

d	B	C	D	E
A	1	3	2	4
B		3	2	3
C			1	3
D				5

3. Clustering par partitionnement

Construction d'une partition des données en k groupes : K est choisi à l'avance


K-means (ou centres mobiles)

Un algorithme très connu de clustering par partitionnement.

3.1. Principe de l'algorithme K-mean

- Si on connaît les centres de gravité μ_k , $k = 1, \dots, K$, on affecte un point x_i à un cluster et un seul. Le point est affecté au cluster C_ℓ dont le centre μ_ℓ est le plus proche
- Connaissant les clusters C_k , $k = 1, \dots, K$, on estime leur centre de gravité
- On alterne ainsi l'affectation des points aux clusters et l'estimation des centres de gravité jusqu'à convergence du critère

3.2. Illustration



3.3. Le pseudo-code de l'algorithme

K-MEANS(D, k, ϵ)

$t = 0$

Initialiser k centroïdes de manière aléatoire : $\mu^t_1, \mu^t_2, \dots, \mu^t_k \in \mathbb{R}^d$

Repeat

$t \leftarrow t + 1$

$C_j \leftarrow \emptyset$ pour tout $j = 1, \dots, k$

// Déterminer les clusters

Foreach $x_j \in D$ do

$j^* \leftarrow \operatorname{argmin}_i \{ \|x_j - \mu^t_i\|^2 \}$ // Affecter x_j au centroïde le plus proche

$C_{j^*} \leftarrow C_{j^*} \cup \{x_j\}$

//Mise à jour des centroïdes

Foreach $i = 1$ to k do

$\mu^t_i \leftarrow \frac{1}{|C_i|} \sum_{x_j \in C_i} x_j$

Until $\sum_{i=1}^k \|\mu^t_i - \mu^{t-1}_i\|^2 \leq \epsilon$

EXERCICE D'APPLICATION

On considère l'ensemble $C = \{2,3,4,10,11,12,20,25,30\}$

Utilisez l'algorithme k-mean avec: $k=2$, $\mu_1 = 2$, $\mu_2=4$

EXERCICE PRATIQUE

On considère les données « Cereals » à télécharger du site « machine learning repository »

- 3.5.** Utiliser l'algorithme k-mean avec respectivement $k=5$ puis $k=3$ pour identifier les groupes (utiliser les logiciels WEKA et PYTHON)
- 3.6.** Quelle est à votre avis la solution la plus satisfaisante ?