
Système d'analyse de sentiments et d'opinions en français

Document de brainstorming – Architecture complète

Projet d'application en Data Mining

UFR	ENEAM / UAC
Niveau	Master 2 – Informatique Décisionnelle
Année	2025–2026
Système retenu	Analyse de sentiments et d'opinions
Langue cible	Français

Table des matières

1 Compréhension et recadrage du sujet	2
1.1 Reformulation des objectifs	2
2 Vue d'ensemble de l'architecture	2
3 Couche 1 – Interface graphique	3
4 Couche 2 – Prétraitement du français	3
5 Couche 3 – Moteur de sentiment (le cœur du projet)	3
5.1 (A) Approche lexicale	3
5.2 (B) Approche Machine Learning	3
5.3 Synthèse comparative des approches	3
6 Couche 4 – Données, entraînement et choix du modèle optimal	4
6.1 Jeux de données français	4
6.2 Protocole de sélection (le « modèle optimal »)	4
6.3 Outils d'entraînement	4
7 Le mode « réseaux sociaux » : réalité et stratégie	4
8 Pile technique et organisation du projet	4
8.1 Pile	4
8.2 Arborescence cible	4
9 Plan de réalisation (jalons)	5
10 Risques et limites à documenter	5
11 Synthèse des décisions	5

1. Compréhension et recadrage du sujet

Le cahier des charges demande de **concevoir une application graphique** (Python ou Java) pour l'un des deux systèmes de data mining proposés. Nous retenons le **système d'analyse de sentiments et d'opinions**.

Exigence du cahier des charges

L'application doit pouvoir analyser **trois types d'entrées** : **(1)** des *phrases isolées*, **(2)** des *textes / documents*, **(3)** des *données en provenance des réseaux sociaux* — le tout **en français**. Elle doit s'appuyer sur les **deux grandes approches** citées : l'approche **Machine Learning** et l'approche **lexicale**.


C'est le point structurant : le projet n'est *pas* un simple pipeline de collecte de tweets, mais une **application interactive** dont le moteur combine deux familles de méthodes, avec une finalité **d'aide à la décision** (recherche marketing, supervision des réseaux sociaux, prise de décision), exactement comme l'énumère le sujet.

1.1 Reformulation des objectifs

- Classer un contenu français en **positif / neutre / négatif** (et, en option, détecter l'*émotion* et les *aspects*).
- Offrir une **interface graphique** couvrant les 3 modes d'entrée.
- Implémenter et **comparer** l'approche lexicale et l'approche ML, puis sélectionner le modèle **optimal** sur des métriques objectives.
- Produire des **visualisations décisionnelles** (distribution, tendances, termes saillants) et un export exploitable.

2. Vue d'ensemble de l'architecture

L'application est organisée en couches faiblement couplées. Le *moteur de sentiment* est le cœur ; l'interface et les sources ne sont que des adaptateurs autour de lui.



3. Couche 1 – Interface graphique

Décision de conception

Streamlit comme interface principale (web, Python pur, déjà présent dans l'environnement **datamining**). Alternatives possibles : **NiceGUI** (web, plus riche) ou **CustomTkinter** (bureau natif).

Trois onglets, alignés sur les trois modes exigés :

1. **Phrase isolée** : champ de saisie → polarité + score + justification (mots déclencheurs surlignés).
2. **Texte / document** : import `.txt`, `.csv`, `.pdf` → analyse phrase par phrase + synthèse agrégée.
3. **Réseaux sociaux** : collecte (scraper) ou import d'un jeu de données → analyse de masse, tendances, termes saillants.

Un **sélecteur de moteur** (lexique / ML classique / transformer) permet de basculer entre les approches et de **comparer** les résultats en direct — ce qui matérialise visuellement l'exigence du sujet.

4. Couche 2 – Prétraitement du français

Étape critique car la qualité de l'analyse en dépend.

- Normalisation : minuscules, URLs / mentions / hashtags, espaces.
- **Emojis** : conversion en tokens de sentiment (porteurs forts).
- **Négation** : marquage (« ne...pas ») car elle inverse la polarité — indispensable en français.
- **Intensifieurs** (« très », « vraiment ») et atténuateurs.
- Tokenisation / lemmatisation : **spaCy** (`fr_core_news_md`) ou NLTK.

5. Couche 3 – Moteur de sentiment (le cœur du projet)

Le sujet impose les **deux approches**. Nous les implémentons toutes les deux, ce qui permet une **comparaison** et donne sa valeur scientifique au rapport.

5.1 (A) Approche lexicale

- Ressource : un **lexique de sentiments français** — **FEEL** (French Expanded Emotion Lexicon), **Polarimots**, ou un portage de **VADER** pour le français.
- Calcul : score = somme pondérée des polarités des termes, **modulé** par la négation, les intensifieurs et les emojis.
- Atouts : **zéro entraînement**, totalement **explicable** (on montre les mots qui ont compté). Sert de **baseline**.
- Limite : faible sur l'ironie, le contexte, le vocabulaire nouveau.

5.2 (B) Approche Machine Learning

Deux niveaux, du plus « data mining classique » au plus performant.

B.1 – ML classique (cœur « data mining »). Vectorisation **TF-IDF / sac-de-mots** puis classifieurs : **Naïve Bayes multinomial**, **SVM linéaire**, **Régression logistique**, **Random Forest** (et **XGBoost** en option). C'est la partie qui mobilise directement les techniques du cours (apprentissage supervisé, évaluation, sélection de modèle).

B.2 – Transformers (état de l'art français). **CamemBERT** (ou **DistilCamemBERT**, plus léger) **fine-tuné** sur un corpus de sentiment français, via la librairie **Hugging Face Transformers (Trainer)**. Meilleure précision, gère mieux le contexte.

Décision de conception

Volet « innovation » (facultatif mais valorisant) : fine-tuning d'un **petit LLM français** (type Mistral / Llama instruct) avec **Unsloth** en **QLoRA 4-bit**. Unsloth divise par ≈ 2 le temps d'entraînement et l'empreinte mémoire — adapté à un GPU modeste. Intérêt : au-delà de la classe, le LLM peut produire une **justification** et extraire les **aspects** (« le service est lent mais le produit est bon »).

5.3 Synthèse comparative des approches

Approche	Entraînement	Explicabilité	Performance attendue (FR)
Lexicale (FEEL)	Aucun	Très forte	Moyenne (baseline)
ML classique TF-IDF	Léger	Forte	Bonne
CamemBERT fine-tuné	Moyen (GPU)	Faible	Très bonne
LLM + Unsloth (QLoRA)	Lourd (GPU)	Moyenne (justifié)	Très bonne + aspects

6. Couche 4 – Données, entraînement et choix du modèle optimal

6.1 Jeux de données français

- **Allociné** : critiques de films (polarité binaire) – grand, propre.
- **Avis / tweets français annotés** (Hugging Face Hub : `tblard/allocine`, corpus de tweets FR, etc.).
- **Corpus maison** : quelques centaines de messages annotés à la main (positif/neutre/négatif) pour évaluer sur *ton* domaine réel.

6.2 Protocole de sélection (le « modèle optimal »)

1. Découpage **train / validation / test + validation croisée**.
2. Métriques : **exactitude, précision, rappel, F1-macro, matrice de confusion**.
3. **Comparaison** : lexique vs ML classique vs CamemBERT (vs LLM).
4. Le meilleur F1-macro sur le jeu de test = **modèle retenu** en production dans l'application.

Exigence du cahier des charges

C'est cette démarche comparative et chiffrée qui constitue le « data mining » attendu : on ne choisit pas un modèle au hasard, on **démontre** son optimalité.

6.3 Outils d'entraînement

`scikit-learn` (ML classique), `Hugging Face Transformers` + `PyTorch` (CamemBERT), `Unsloth` + `PEFT/QLoRA` (LLM). Suivi des expériences : `matplotlib` pour les courbes, export des métriques en CSV.

7. Le mode « réseaux sociaux » : réalité et stratégie

Point de vigilance

En 2026, le **scraping de Facebook déconnecté est bloqué** : `mbasic` renvoie une erreur HTTP 400. Toute collecte réelle exige une **session authentifiée** (donc hors CGU), ou une **API tierce payante**.

Stratégie pragmatique pour ne **jamais** dépendre du scraping le jour de la soutenance :

1. **Dataset de secours** (recommandé) : un corpus de tweets / avis FR déjà collecté, chargé dans le mode « réseaux sociaux ». La démo fonctionne à coup sûr.
2. **Scraper (apprentissage)** : module `scraper_fb.py` déjà en place (`sentiment/`). Fonctionne avec un **compte dédié** + cookie de session, ou via **Playwright** pour le contenu dynamique. À présenter avec ses limites et le cadrage **RGPD** (Pages publiques seulement, anonymisation par hachage, faible débit).
3. **Option robuste** : API tierce (Apify) si un petit budget existe.

8. Pile technique et organisation du projet

8.1 Pile

Python 3.12 (uv); `scikit-learn`, `pandas`, `spacy/nltk`; `transformers+torch`; `unsloth` (option); `streamlit`; `matplotlib/plotly`, `wordcloud`; `requests/beautifulsoup4/playwright` (collecte).

8.2 Arborescence cible

```
datamining/sentiment/
  app.py                # interface Streamlit (3 onglets)
  pretraitement.py      # nettoyage FR, negation, emojis
  moteur_lexical.py     # approche lexicale (FEEL)
  moteur_ml.py          # TF-IDF + classifieurs sklearn
  moteur_transformer.py  # CamemBERT (Hugging Face)
  entraînement/         # scripts d'entraînement + benchmark
  scraper_fb.py         # collecte reseaux sociaux (deja present)
  data/                 # datasets FR + corpus maison annote
  modeles/              # modeles entraines sauvegardes
  resultats/            # metriques, matrices de confusion
```

9. Plan de réalisation (jalons)

#	Jalon	Contenu
1	Prétraitement + lexique	Baseline explicable qui tourne de bout en bout
2	ML classique	TF-IDF + classifieurs, dataset FR, premier benchmark
3	CamemBERT	Fine-tuning Hugging Face, comparaison
4	(option) LLM + Unsloth	QLoRA, justification + aspects
5	Interface Streamlit	Les 3 modes + sélecteur de moteur
6	Mode réseaux sociaux	Dataset de secours + scraper + RGPD
7	Évaluation + rapport	Modèle optimal, visualisations, rédaction

10. Risques et limites à documenter

- **Ironie / sarcasme** : difficiles pour tous les modèles ; à mesurer.
- **Ressources FR** limitées vs anglais : lexiques et corpus plus rares.
- **RGPD** : données personnelles → anonymisation, base légale, Pages publiques uniquement.
- **Dépendance au scraping** : neutralisée par le dataset de secours.
- **Échantillon non représentatif** : à nuancer dans l'interprétation.

11. Synthèse des décisions

1. Système : **analyse de sentiments FR**, application **Streamlit**.
2. **3 modes d'entrée** (phrase / texte / réseaux sociaux) conformes au sujet.
3. **2 approches** implémentées et comparées : **lexicale** et **ML** (classique + CamemBERT), avec option **LLM + Unsloth**.
4. Modèle **optimal** choisi par **benchmark chiffré** (F1-macro).
5. Mode réseaux sociaux sécurisé par un **dataset de secours** + scraper cadré RGPD.
6. Finalité : **aide à la décision** (visualisations, export).